

云原生场景下内存多级卸载落地实践

曾敬翔

腾讯资深内核研发专家

云原生场景下内存多级卸载落地实践


方案背景

云原生场景下内存多级卸载落地实践

产业背景 — 内存需求成本不断上升、有效利用率较低


- 服务器在数据中心硬件采购成本中占比最高，达到80%左右
 - 其中CPU、GPU和DRAM是主要成本项
- 数据中心应用程序对内存的需求持续增长
 - 随着数据量和业务复杂度上升，内存需求陡增
- 业务内存中不活跃冷内存占有很大比例
 - 比例值根据业务不同会有波动
- 应用程序为了提高性能，大都采用内存密集性策略
 - 长时间运行或者大量服务并存时会出现很大的内存压力，如内存颠簸、OOM

图 35：各类服务器成本构成




资料来源：IDC，安信证券研究中心

图 57：2017-2025 年 DRAM 需求总量及增速预测





资料来源：中国产业信息网，安信证券研究中心



落地方向 - 业务超卖 & 业务降配 & 混部弹性内存超卖

- 节省负载内存
 - 在容器平台中，对workload开启内存多级卸载，可以平均回收40%的冷内存，加上workload在申请memory resources的时候，一般会预留一部分buffer。
- 应用节省内存
 - 业务超卖：对workload开启多级卸载后，增加单pod（CVM）流量，提高TPS、QPS。
 - 负载降配
 - 降低业务成本：对workload开启内存多级卸载后，降低workload resources的memory request和limit，降低平台业务的上云成本。
 - 提高集群装箱率：多数集群节点CPU/MEM是1:2，但是很多大内存workload（1:4，1:8），影响集群装箱率，将大内存workload降配后（1:8 -> 1:4），以提高集群装箱率。
- 混部弹性内存超卖
 - 提高内存混部率：把非内存敏感型workload开启内存多级卸载，节省出多余的空闲内存资源，可以调度更多的离线（低优先级）pod上来，并且，在整机内存压力大的情况下，优先迁出、OOM调离线（低优先级）pod。



云原生场景下内存多级卸载落地实践

整体解决方案

落地过程中遇到的问题


- 内存多级卸载方案在容器平台落地遇到的问题
 - **回收路径难以确定**：内存多级卸载的回收名单是cgroup path list，但是在容器平台中，pod cgroup path是一串哈希值，并且pod会在集群的node中间迁入迁出，如何确定node上哪些pod需要开启内存多级卸载，并且随着pod状态的改变，实时改变回收名单？
 - **回收参数难以确定**：在容器平台中，需要开启内存多级卸载的workload对内存回收的敏感程度是不一样的，如何判断workload类型，然后使用对应回收参数？
 - **主动回收导致的问题**：
 - **误回收“冷”文件页**：主动回收额外的文件页面，由于当前lru精度比较单调，导致误回收一些将会访问的页面，导致cache miss，造成读IOPS增加。
 - **过度压缩匿名页**：在主备存储模型中，备份节点一直处于空闲状态，因为PSI一直表征空闲情况，内存多级卸载不断将其匿名页面压缩到zram，突然的主备切换，导致备节点突增大量请求，所有在zram的页面基本都需要解压，造成颠簸的延迟反应。
 - **zram的页面无法统计**：workload的resources.limits.memory是对memory.usage_in_bytes做限制，但是压缩在zram的匿名页面无法被限制，会造成计数器泄露的问题，pod可能无限制得利用node上的zram资源，而k8s感知不到。
 - **隔离非内存多级卸载pod的换出行为**：当对node节点开启zram的时候，虽然不对非内存多级卸载pod做主动回收，但在非内存多级卸载pod容器内存紧缺的情况下、或者整机内存紧缺的情况下，依然有可能把非内存多级卸载pod的匿名页面压缩到zram中，改变客户原本的预期行为。
 - ...

云原生场景下内存多级卸载落地实践



整体架构

- wujing-umrd daemonset:
 - qos-agent container: 在node上, 找到哪些pod打开了多级卸载, 并且把pod cgroup和回收参数发送到umrd ds.
 - umrd container: umrd根据qos-agent传递过来的回收列表进行主动回收, 并且根据回收参数、PSI、refault计算回收文件页、匿名页的数量。
- mglru增强模块:
 - 拆分接口: 文件页面、匿名页面独立扫描、回收。
 - Workingset Evaluation: 评估有效文件页回写数量。
 - new workingset refault feature: 优化mglru workingset。
- swap隔离模块: system disable、cgroup disable
- zram增强模块: per-cgroup zram priority、per-cgroup zram counter (raw、limit、usage)
- 热度探测模块: 匿名段热度探测, 容器总匿名页、文件页面热度探测。

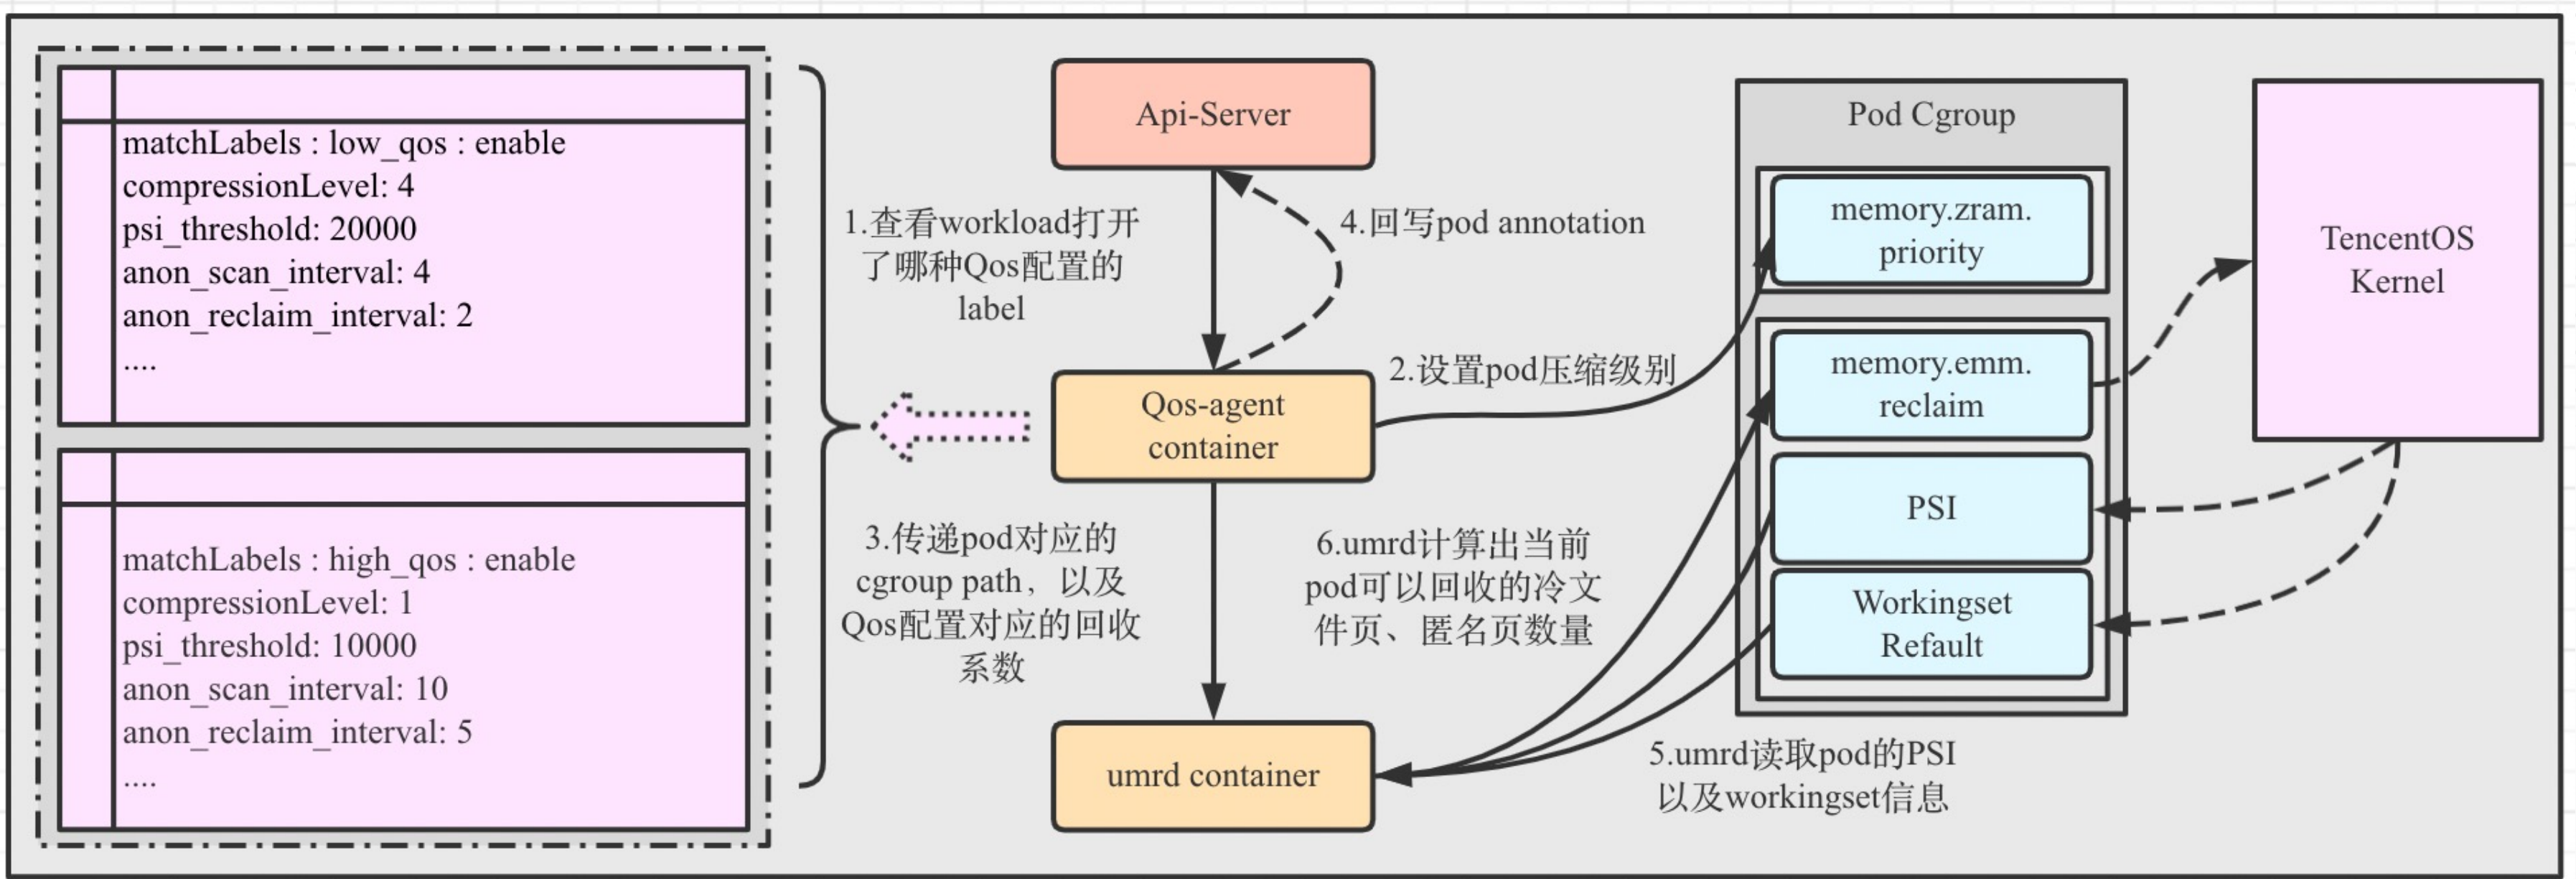


云原生场景下内存多级卸载落地实践

子模块介绍

wujing-umrd ds

- 在集群中部署wujing-umrd ds，集群中每个node都会被调度上一个wujing-umrd pod，其中，wujing-umrd ds包含一个qos-agent container和umrd container。
- qos-agent container：当node上pod状态发生变化的时候，根据pod yaml打的QOS标签，对pod开启多级卸载，并且启用QOS标签对应的压缩等级和回收参数。
- umrd container：接受qos-agent container传递的回收路径和回收参数，并且根据PSI、refault负反馈决定当前回收的页面数量。



mglru增强

mglru:

- 精度提升：传统LRU 仅使用两个lru list (Active/Inactive) 来区分页面热度。而MGLRU中将 LRU 分成了四个世代 (Gen)，每个世代中又分为 4 个层级 (Tier)。表征页面精度的提升，意味着误回收“冷”页的可能性下降。

mglru拆分接口:


- 将mglru文件页、匿名页的扫描和回收过程隔离，并且给出同一的用户接口。
- 使用方式，例如：
 - 对于访问频繁的匿名页面，可以10s扫描一次，5s回收一次。
 - 对于慢盘并且访问少的文件页，可以20s扫描一次，2s回收一次。

Workingset Evaluation:

- 可以获取一个 Cgroup 过去 1分钟/10分钟/30分钟 内平均 Refault 距离, 以及预估有效文件页回写数量。

workingset refault重构与优化:

- 对 Linux 内核中传统 LRU 长期使用的 Workingset Refault Distance 算法进行了重新优化设计，并成功将其与 MGLRU 中的 Refault PID 算法结合。
- 改进后的算法可以辅助不同场景下进行更加有效的页面平衡，并能更加有效地防止 Thrashing。新算法在一些应用场景中有着非常显著的性能提升（5% - 400%）。即使是在传统 LRU 场景下，新算法也有可见性能提升（1 - 5%）。部分改进已发至上游。




swap隔离

在集群原本没有开启swap，在使用多级卸载后，将会把集群的swap打开，对于非多级卸载pod，在整机、容器内存紧缺的情况下，会将匿名页面换出到swap设备，这是业务非预期行为，得支持swap的隔离。

- 整机内存紧缺：在整机内存紧缺的情况下，内核内存子系统会从root memcg开始遍历memcg，并且回收其lruvec，由于可能会对非多级卸载的pod做回收。
- 容器内存紧缺：在容器内存紧缺的情况下，内核内存子系统会从当前memcg开始遍历memcg，并且回收其lruvec，如果当前memcg没有开启多级卸载，那么会导致业务的匿名页面换出到swap上。

接口与解决办法：

- 内核接口：vm.force_swappiness、memory.swappiness
- qos-agent：qos-agent对开启多级卸载的集群，设置vm.force_swappiness=1，强制在整机、容器内存紧缺的情况下，强制对swappiness==0的容器不回收匿名页面；并且，在node上pod状态发生变化时，对非多级卸载pod设置swappiness=0，多级卸载pod设置swappiness=60。



zram增强

ZRAM Enhance基于上游 Object Cgroup API 实现, 每个 Cgroup 提供了:

独立更改 ZRAM 压缩级别:

- `<cgroup>/memory.zram.priority`: 每个 Cgroup 可以选择压缩等级 1 - 4, 默认分别对应算法 lz4, lzo-rle, lz4hc, zstd, 压缩率由高到低, 性能损失由小增大。


独立统计 ZRAM 压缩数据:

- `<cgroup>/memory.zram.raw_in_bytes`: 以 Byte 为单位的换出到zram压缩前的数据大小
- `<cgroup>/memory.zram.usage_in_bytes`: 以 Byte 为单位的换出到zram压缩后的总数据大小

限制 ZRAM 压缩量

- `<cgroup>/memory.zram.limit_in_bytes`: 以Byte为单位, 限制本memcg换出到zram的总数据大小, 超出这个限制后, 匿名页面将无法换出到zram设备。

同时, zram压缩后的数据大小会计算到memory.usage_in_bytes上, 方便k8s感知和限制。



云原生场景下内存多级卸载落地实践

落地效果

云原生场景下内存多级卸载落地实践




落地效果

目前内存多级卸载在腾讯在线容器平台、离线容器平台、混部容器平台都已成熟应用，覆盖业务含：键值存储、文件存储、聊天图片存储、聊天消息存储、AI平台、游戏AI训练、转码、数据库等。主要收益场景：超卖、降配、混部。

超卖场景：

- 内存节省：提升单机的内存售卖率，降低内存存储的成本。相同数据量情况下，开启多级卸载，内存用量降低35%。
- 延迟情况：请求延时基本没有波动（单位：ms）。






非多级卸载	avg	p99	max	多级卸载	avg	p99	max
redis-benchmark-1	0.622	1.073	11.15	redis-benchmark-1	0.649	1.075	3.463
redis-benchmark-2	0.15	0.983	4.373	redis-benchmark-2	0.16	0.983	2.429
redis-benchmark-3	0.151	0.983	3.206	redis-benchmark-3	0.161	0.983	2.432
redis-benchmark-4	0.622	1.073	11.319	redis-benchmark-4	0.649	1.075	3.646

落地效果

降配场景：

- 内存节省：对workload开启多级内存卸载，稳定降低内存用量后，降低workload的配置，节省业务上云成本。
- 性能：降低业务workload 86%的OOM数量。





落地效果

混部场景：

- 内存节省：在混部集群中，节点内存接近打满，但CPU利用率还有空闲，此时内存资源成为混部瓶颈。对非内存敏感型workload开启多级卸载后，节省出额外的内存资源，部署更多的离线pod。
- 性能：无影响（出现影响优先kill离线pod）。

```
root@~# free -g
```

	total	used	free	shared	buff/cache	available
Mem:	187	69	95	11	22	104
Swap:	187	38	148			



OpenCloudOS介绍

Join us

OpenCloudOS愿景与定位



腾讯将基于自身的操作系统技术积累和能力，与合作伙伴一起，全力支持OpenCloudOS社区的建设。因为社区中立的属性，截止目前不到一年时间吸引200+生态企业投入并且共同推动社区的繁荣发展。

社区愿景

由操作系统、软硬件厂商与个人共同倡议发起的操作系统社区项目，提供自主可控、绿色节能、安全可靠、高性能的下一代云原生操作系统，与生态伙伴一起打造中立的操作系统开源生态。

社区定位

从自主可控源社区(L1)、商业版(L2)、到社区稳定版(L3)的全链路覆盖，输出经海量业务验证的企业级稳定操作系统版本。避免断供风险，为行业提供可控的操作系统上下游供应，做中国操作系统全链路供应标杆。


自主可控的下一代云原生操作系统



下一代云原生操作系统以容器为中心，虚拟化技术主要用于容器隔离，能更好地支持Serverless/FaaS场景。
通过参与贡献国际顶级开源项目获得原创技术能力，从而实现全栈国产化、自主可控的下一代云原生操作系统。

特征	轻量化
	Safety（可靠性）
	Security（安全性）
解决痛点	解决版本碎片化的问题
	容器运行时与内核结合问题
	多租户安全隔离问题
优势	支撑业务敏捷发布
	支撑业务长时间稳定运行
	支撑业务快速弹性伸缩


全栈国产化




智能弹性的下一代云原生操作系统

智能弹性多优先级混部有效降低成本：OpenCloudOS通过分时弹性资源QoS，实现智能弹性多优先


级混部核心能力，满足企业最低成本实现数据化转型及计算数据上云。



CPU/内存 request总量减少45%左右



Pod规格从主流8-16核减少为1-4核




绿色低碳的下一代云原生操作系统



助力国家“碳中和”战略：OpenCloudOS的“悟能”技术系统，通过在操作系统级别CPU弹性运行与深度睡眠，结合功耗监控和细粒度的电源管理，软硬件结合达到节能目的。

- 实测结果：**减少5%-30%的能源消耗、小于0.1%的性能损耗
- 腾讯应用：服务器整机功耗省5-30%，腾讯数据中心整体能耗省6亿KWH/年，减少碳排放24万吨/年
 - 宏观应用：可推广到所有IDC，减少所有IDC 5-30%碳排放，**对国家整体碳中和战略有长远的重要意义。**



Thanks_

购买多级卸载——Tel: 18813145407